

# 计算机科学与技术学院神经网络与深度学习课程实验报告

实验题目：cGAN-pyTorch		学号：201900130143
日期：11/25	班级：智能班	姓名：吴家麒
Email：wj_777@126.com		
<p>实验目的：</p> <p>In this assignment, you will also explore methods for visualizing the features of a pretrained model on ImageNet.</p> <ul style="list-style-type: none"><li>• Explore various applications of image gradients, including saliency maps, fooling images, class visualizations</li></ul>		
<p>实验软件和硬件环境：</p> <p>Anaconda3 + Jupyter notebook</p>		
<p>实验原理和方法：</p> <p>GAN 网络由 Generator 和 Discriminator 组成。Generator 可以看作是一个输出一种分布而不是一个特定值的 Network。输入是 <math>z</math> 一个从已知分布中采样得到的，利用不同的 <math>z</math>，针对同一个 <math>x</math> 生成不同的 <math>y</math>，来达到输出是一个分布的目的。</p> <p>我们的目标是让生成的数据的分布和真实的数据的分布越接近越好。</p> <p>这时我们利用 Divergence 来表示生成数据和真实数据之间的差异。</p> <p>Discriminator 的目标就是给真实图像一个比较大的分数，给生成图像一个比较小的分数，对生成的图像和真实的图像进行分类判别。</p> <p>The diagram illustrates the architecture of a Generative Adversarial Network (GAN). It consists of two main components: the Generator (G) and the Discriminator (D). The Generator takes a noise vector <math>z</math> (represented by five blue circles) as input and produces a generated image <math>y</math> (represented by five green circles). The Discriminator takes both a real image <math>x</math> (represented by five blue circles) and a generated image <math>y</math> (represented by five green circles) as input and outputs a score <math>D(x y)</math> (represented by a single black circle). The Generator is labeled <math>G(z y)</math> and the Discriminator is labeled <math>D(x y)</math>.</p>		

cGAN 也就是 ConditionalGenerativeAdversarialNetwork，在基本的 GAN 上对 Generator 和 Discriminator 的输入都添加了 labels,使得我们可以针对类别训练，控制生成图片的类别，而使得结果不那么随机。

我们使用 Fashion-Mnist 数据集来进行 CGAN 模型的训练，数据集一共有 10 种不同种类的衣服数据：Dress, Coat, Shirt 等等。训练集规模有 60000 条数据。

实验步骤：（不要求罗列完整源代码）

### 1、Generator

输入：潜在空间的一批点（向量）和一批 label

输出：一批图片

```
class Generator(nn.Module):
    def __init__(self):
        super(Generator, self).__init__()

        self.label_embedding = nn.Embedding(opt.n_classes, opt.label_dim)
        ## TODO: There are many ways to implement the model, one alternative
        ## architecture is (100+50)--->128--->256--->512--->1024--->(1, 28, 28)

        ### START CODE HERE
        def block(in_feat, out_feat, normalize=True):
            layers = [nn.Linear(in_feat, out_feat)]
            if normalize:
                layers.append(nn.BatchNorm1d(out_feat, 0.8))
            layers.append(nn.LeakyReLU(0.2, inplace=True))
            return layers

        self.model = nn.Sequential(
            *block(opt.latent_dim + opt.label_dim, 128, normalize=False),
            *block(128, 256),
            *block(256, 512),
            *block(512, 1024),
            nn.Linear(1024, int(np.prod(img_shape))),
            nn.Tanh()
        )
        ### END CODE HERE

    def forward(self, noise, labels):
        ### START CODE HERE
        gen_input = torch.cat((self.label_embedding(labels), noise), -1) #拼接两个向量
        img = self.model(gen_input)
        img = img.view(img.size(0), *img_shape)
        return img
        ### END CODE HERE

    return img
```

### 2、Discriminator

输入：一批图片和图片对应的 label

输出：判别的结果

```

class Discriminator(nn.Module):
    def __init__(self):
        super(Discriminator, self).__init__()

        self.label_embedding = nn.Embedding(opt.n_classes, opt.label_dim)
        ## TODO: There are many ways to implement the discriminator, one alternative
        ## architecture is (100+784)-->512-->512-->512-->1

        ### START CODE HERE
        self.model = nn.Sequential(
            nn.Linear(opt.label_dim + int(np.prod(img_shape)), 512),
            nn.LeakyReLU(0.2, inplace=True),
            nn.Linear(512, 512),
            nn.Dropout(0.4),
            nn.LeakyReLU(0.2, inplace=True),
            nn.Linear(512, 512),
            nn.Dropout(0.4),
            nn.LeakyReLU(0.2, inplace=True),
            nn.Linear(512, 1),
        )
        ### END CODE HERE

    def forward(self, img, labels):

        ### START CODE HERE
        d_in = torch.cat((img.view(img.size(0), -1), self.label_embedding(labels)), -1)
        validity = self.model(d_in)
        ### END CODE HERE

        return validity

```

网络结构可以看作是图像从 (784+100) → 512 → 512 → 512 → 1 的过程。

### 3. 训练过程

生成器的训练首先输入  $z$  和  $label$  生成一批图片，再通过判别器判断生成图片的真假，计算 generator 的 loss，然后计算反向传播更新参数。

```

# -----
# Train Generator
# -----

### START CODE HERE
optimizer_G.zero_grad()

# Sample noise and labels as generator input
# 生成一批 noise
z = Variable(FloatTensor(np.random.normal(0, 1, (batch_size, opt.latent_dim))))
# 生成一批 label
gen_labels = Variable(LongTensor(np.random.randint(0, opt.n_classes, batch_size)))

# 输入 z 和 gen_labels，通过生成器，生成一批图片
gen_imgs = generator(z, gen_labels)

# Loss measures generator's ability to fool the discriminator
# 通过判别器，判断生成图像的真假，返回一批图像的判别结果
validity = discriminator(gen_imgs, gen_labels)
# 判别为假的产生 loss，这里计算生成器的 loss
g_loss = adversarial_loss(validity, valid)
# BP + 更新
g_loss.backward()
optimizer_G.step()
### END CODE HERE

```

判别器的训练：分别计算出真实图片的 loss 和生成图片的 loss，得到总的损失进行反向传播和参数更新。

```

# -----
# Train Discriminator
# -----

### START CODE HERE

optimizer_D.zero_grad()

# 计算真实图片的 loss
validity_real = discriminator(real_imgs, labels)
d_real_loss = adversarial_loss(validity_real, valid)


# 计算生成图片的 loss
validity_fake = discriminator(gen_imgs.detach(), gen_labels)
d_fake_loss = adversarial_loss(validity_fake, fake)

# Total loss
d_loss = (d_real_loss + d_fake_loss) / 2

# BP + 更新
d_loss.backward()
optimizer_D.step()
### END CODE HERE

```

最后测试，生成图像：



结论分析与体会：

- 1、从本次实验的结果中可以发现，GAN 训练的超参数很多，一定幅度调参对结果的影响很大，也可以看出 GAN 存在一定的局限性。
- 2、通过本次实验对 GAN 的原理与训练过程进行了学习和运用，对对抗生成网络的实际训练过程有了更深入的理解。
- 3、对于神经网络在实际应用中的过程有了更为深入的理解和学习。